Diagnóstico y corrección de una aplicación de clasificación

Jorge Flores Gonzalez
Atlantis University · MAI 540 · Tarea 3.1 · 4 de octubre de 2026

Diagnóstico

Se revisó la aplicación educativa de biopsias de mama antes de corregirla. Su flujo carga 569 observaciones, agrega columnas sintéticas, construye una característica y entrena una regresión logística. La copia recibida fallaba primero con NameError: una celda llamaba a construir_caracteristicas antes de definirla. Mover ese diagnóstico después de las definiciones permitió reproducir el ValueError por valores infinitos previsto en la consigna.

Para el fallo numérico se contrastaron dos hipótesis con asistencia de IA: H1, las columnas originales ya contenían valores no finitos; H2, la función de ingeniería los introducía. La validación previa no encontró problemas en textura y biopsias previas. Después de dividir, la captura de Colab registró 141 infinitos, todos con cero biopsias previas. Se descartó H1 para las columnas revisadas y se confirmó H2. Ese conteo pertenece a la ejecución diagnóstica: cada llamada al generador aleatorio global cambia los valores sintéticos.

Para la fuga se contrastó una asociación predictiva disponible antes del diagnóstico con una variable construida a partir de la respuesta. La inspección del código confirmó la segunda explicación: sesiones_tratamiento_programadas asigna de tres a ocho sesiones a malignos y cero a benignos. No es una medición previa independiente. La explicación de predictor legítimo se descartó por su procedencia, no solo por la correlación. Esta interpretación se documentó al revisar la evidencia, sin atribuirla a una hipótesis personal registrada previamente.

Corrección

Se reemplazó únicamente el denominador cero por uno. El cálculo para valores positivos conserva su fórmula y, con cero biopsias, retorna la textura sin dividir. Es una convención educativa explícita, no una regla clínica validada. La ejecución corregida mostró cero valores no finitos. Se excluyó la columna de tratamiento de los nueve predictores finales; target y diagnostico tampoco se usan como entradas. El experimento con fuga conserva una lista separada. La fuga puede inflar la evaluación al utilizar información indisponible para predecir (scikit-learn developers, s. f.-a).

Tabla 1. Accuracy de prueba registrado en Colab

Condición	Accuracy
División sin corregir	No calculable: ValueError
Corregida, con fuga	1.0000
Sin fuga, sin balanced	0.7413
Sin fuga, con balanced	0.7413

Las comparaciones usaron las mismas filas: 426 casos de entrenamiento y 143 de prueba, test_size=0.25 y random_state=42. Retirar la fuga redujo el accuracy en 25.87 puntos porcentuales: se eliminó optimismo artificial. Se reportan las salidas de la ejecución completa del notebook, no las métricas de sesiones anteriores.

Desbalance de clases

El conjunto contiene 62.7% de casos benignos y 37.3% malignos. Ambos modelos sin fuga alcanzaron 74.13%. Balanced pondera inversamente la frecuencia de clases de entrenamiento (scikit-learn developers, s. f.-b). Puede cambiar los errores por clase sin alterar el total de aciertos. Aquí no se afirma que mejore la detección de malignos; sería necesario examinar esos errores.

Refactorización y pruebas

Se conectó validar_datos al inicio de entrenar_modelo. Ante nulos o infinitos se produce un ValueError explicativo antes de ajustar el clasificador. Para entradas válidas se mantienen algoritmo, columnas, partición y parámetros. El notebook descargado se conservó intacto; sus funciones se extrajeron a app_biopsias.py para importarlas desde test_app.py sin ejecutar gráficos ni guardar modelos.

Pytest ejecutó ocho casos y todos pasaron en 2.88 segundos. Se verificaron la fórmula con denominadores cero y positivos, la ausencia de mutación de la entrada, la exclusión de fuga y objetivos tanto en la lista como en el modelo ajustado, y las etiquetas benigno o maligno en los 569 registros. Tres casos adicionales comprobaron el rechazo de NaN, infinito positivo e infinito negativo.

Los dos casos de equivalencia compararon el entrenamiento refactorizado con una referencia que conserva la lógica anterior sin la validación, con y sin balanced. Las predicciones coincidieron en las 569 filas, los coeficientes fueron numéricamente equivalentes y los accuracies de entrenamiento y prueba fueron iguales. La evidencia se conserva en evidencia_pytest.txt. El alcance de estas pruebas es el módulo extraído: no demuestra la corrección de gráficos, serialización ni uso clínico. La preparación fue asistida por IA; corresponde al estudiante revisar la interpretación y la entrega.

Referencias

scikit-learn developers. (s. f.-a). *Common pitfalls and recommended practices.* https://scikit-learn.org/stable/common_pitfalls.html

scikit-learn developers. (s. f.-b). *LogisticRegression.* https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html